Temporal Fusion <u>Transformers</u> for Interpretable Multi-horizon <u>Time Series Forecasting</u>

시계열 예측 모델 최신 경향 분석 & 코드 리뷰 (1)

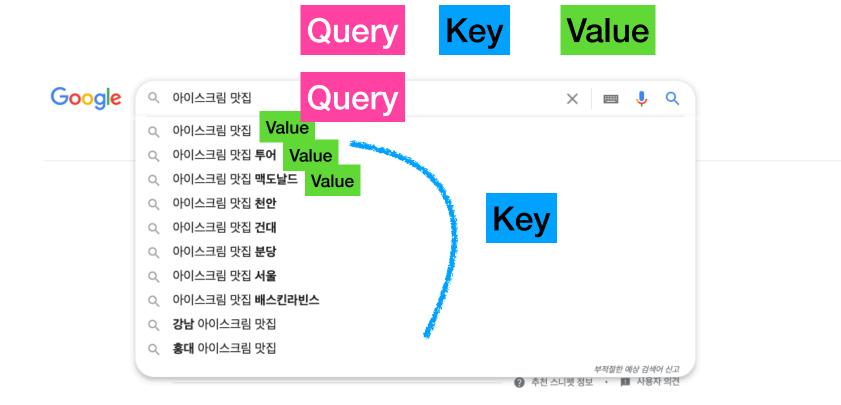
Index

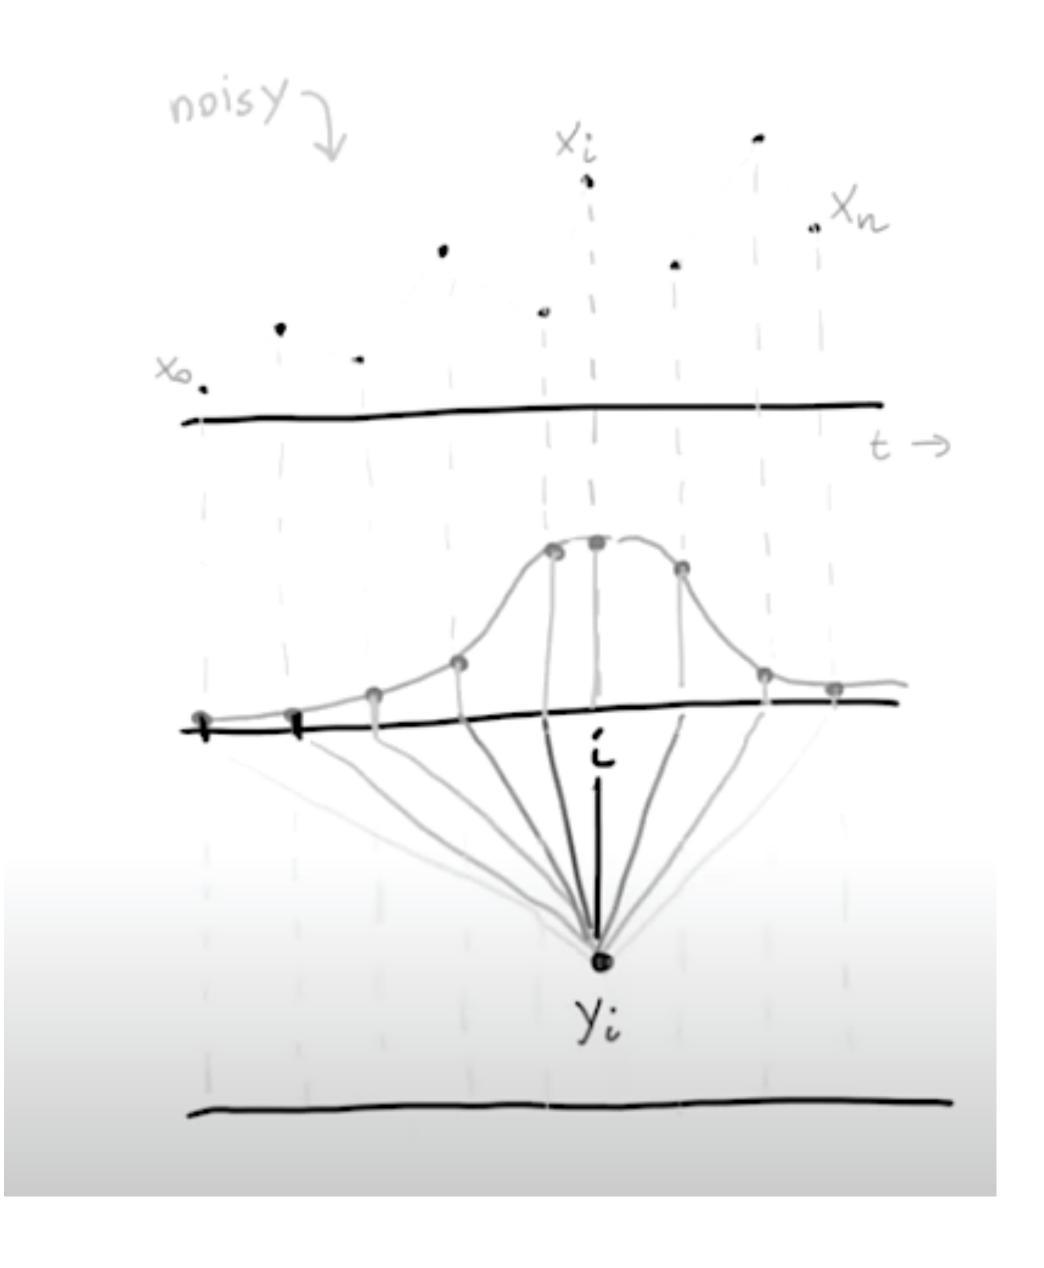
- 1. Transformer: Attention is all you need 요약 정리 (+코드)
- 2. Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting

1-(1). attention 매커니즘

attention 매커니즘 소개

- 취지: auto-regressive 특징을 갖는 데이터에서 특정 시점(t) 의 output 값을 예측할 때 이전 시점 들을 얼마나 고려할지 (각 time step 의 중요도에 따른) 각기 다른 weights 를 구해주자!
- Ex) I love cats -> 나는 ? ?
- 초기 어텐션: timesteps 0~3까지 있다고 하면 Y[i]=softmax(X[i]·X[0]) * X[0] +softmax(X[i]·X[1])*X[1] + softmax(X[i]·X[2])*X[2]
- softmax(X[i] · X[0]) * X[0]





attention 매커니즘 소개

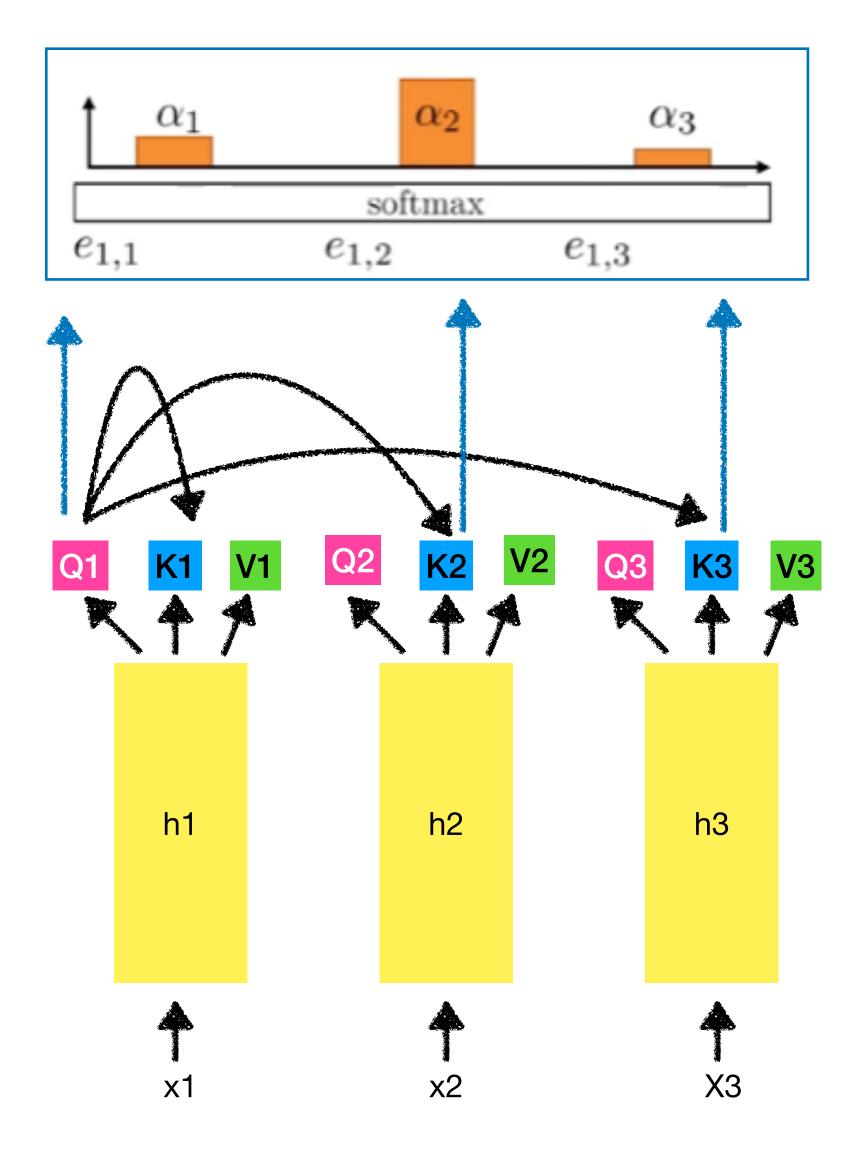
Self-attention

$$\begin{split} \alpha_{l,t} &= \exp(e_{l,t}) / \sum_{t'} \exp(e_{l,t'}) \\ e_{l,t} &= q_l \cdot k_t & \text{we'll see why this is important soon} \\ v_t &= v(h_t) \quad \text{before just had } v(h_t) = h_t, \text{ now e.g. } v(h_t) = W_v h_t \\ k_t &= k(h_t) \text{ (just like before)} \quad \text{e.g., } k_t = W_k h_t \\ q_t &= q(h_t) & \text{e.g., } q_t = W_q h_t \end{split}$$

This is not a recurrent model!

But still weight sharing:

h[t] = sigmoid(Wx[t] +b)



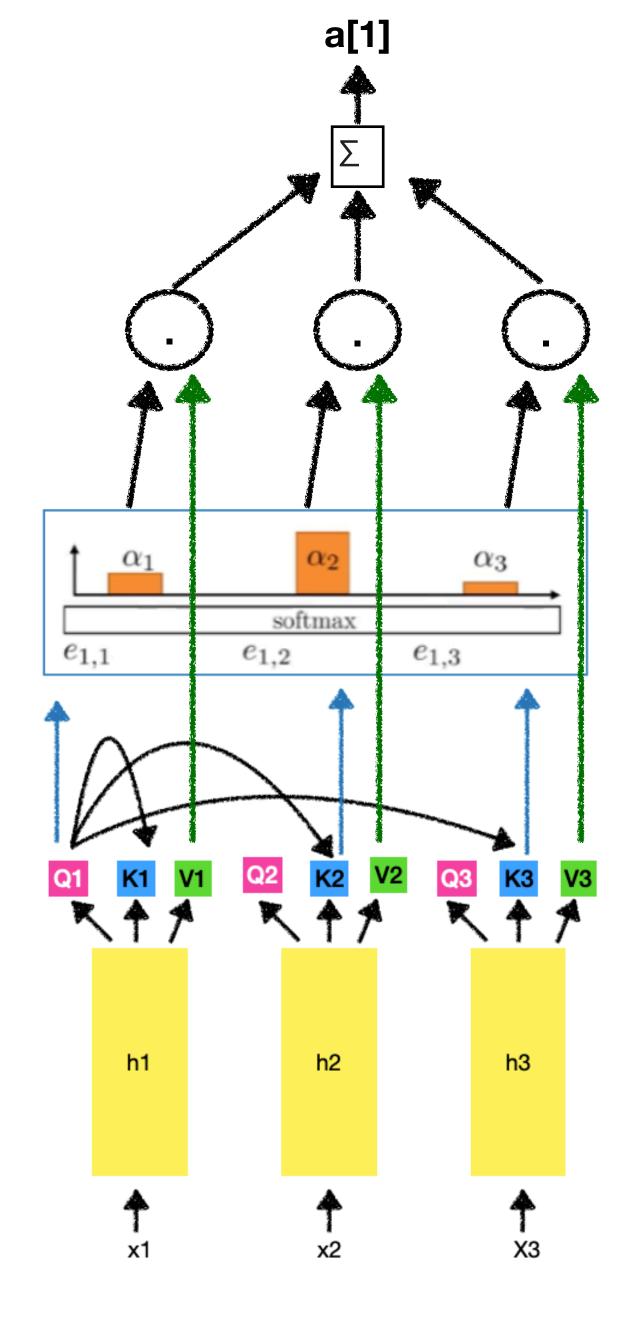
attention 매커니즘 소개 Self-attention

$$\begin{split} \alpha_{l,t} &= \exp(e_{l,t}) / \sum_{t'} \exp(e_{l,t'}) \\ e_{l,t} &= q_l \cdot k_t & \text{we'll see why this is important soon} \\ v_t &= v(h_t) \quad \text{before just had } v(h_t) = h_t, \text{ now e.g. } v(h_t) = W_v h_t \\ k_t &= k(h_t) \text{ (just like before)} \quad \text{e.g., } k_t = W_k h_t \\ q_t &= q(h_t) \quad \text{e.g., } q_t = W_q h_t \end{split}$$

This is not a recurrent model!

But still weight sharing:

h[t] = sigmoid(Wx[t] +b)



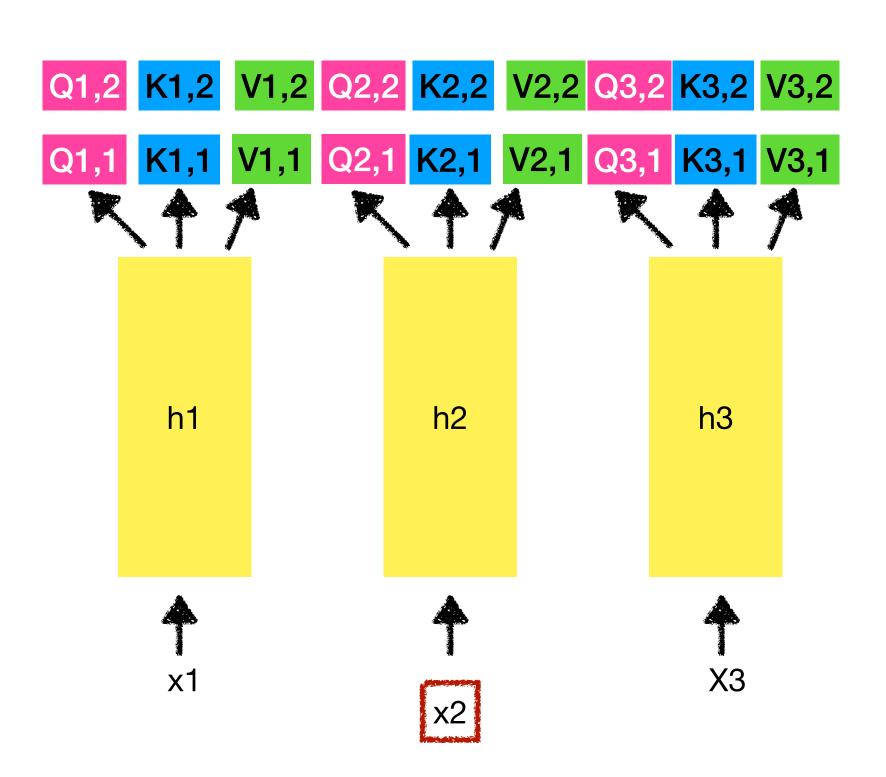
attention 매커니즘 소개

Multi-head attention

- 일반적으로 8개 정도의 head 사용
- 각 head 에서 나온 attention 결과를 concat
- Multi heads 개념은 cnn 의 필터 개념과 흡사



- - -



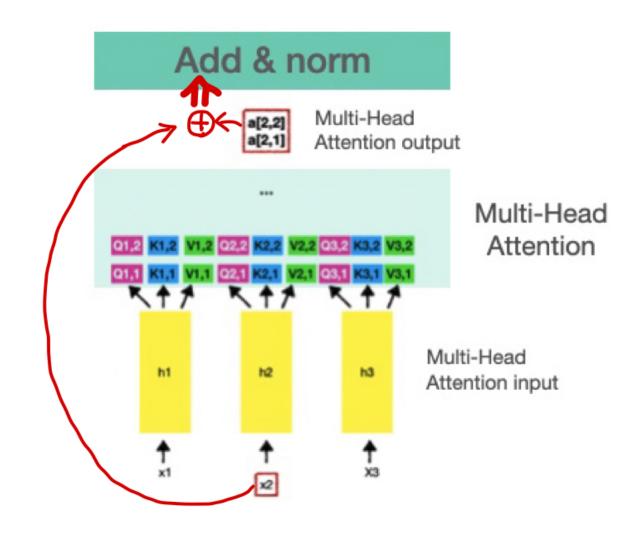
1-(2). 부가적인 개념

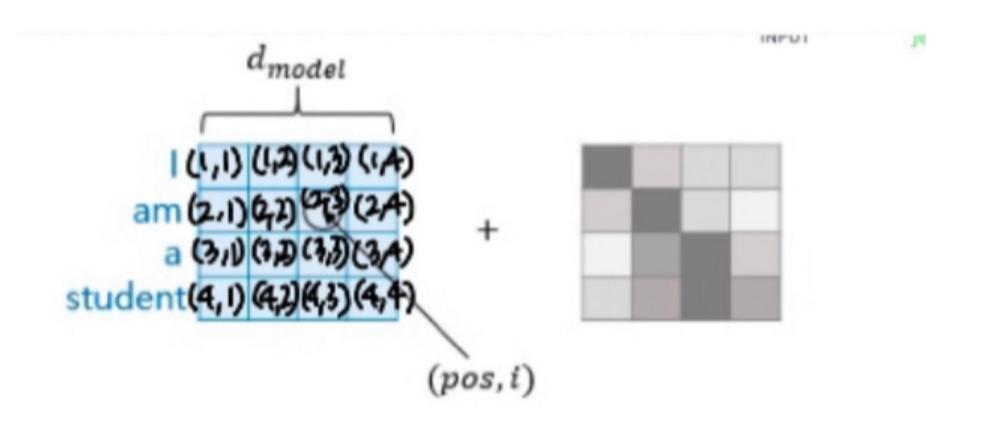
부가적인 개념

Layer normalization (add & norm) Positional encoding

- add&norm 은 레즈넷의 개념과 유사
- 어텐션 메커니즘은 rnn 과 달리 위치 기반이 아니기 때문에 Positional encoding 도입
- Pos 는 전체 시퀀스에서 몇 번째 단어인지를 의미
- i는 임베딩 벡터 내의 인덱스
- Positional encoding 값 = sin(pos/10000^(2k/임베딩 차원)) (i=2k, 즉 i 가 짝수일 때)

Positional encoding 값 = cos(pos/10000^(2k/임베딩 차원)) (i=2k+1,즉 i 가 홀수일 때)

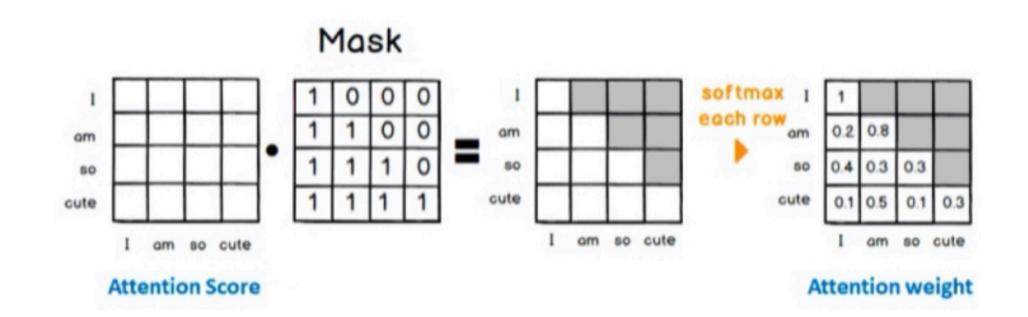




부가적인 개념

Masked multi-head attention

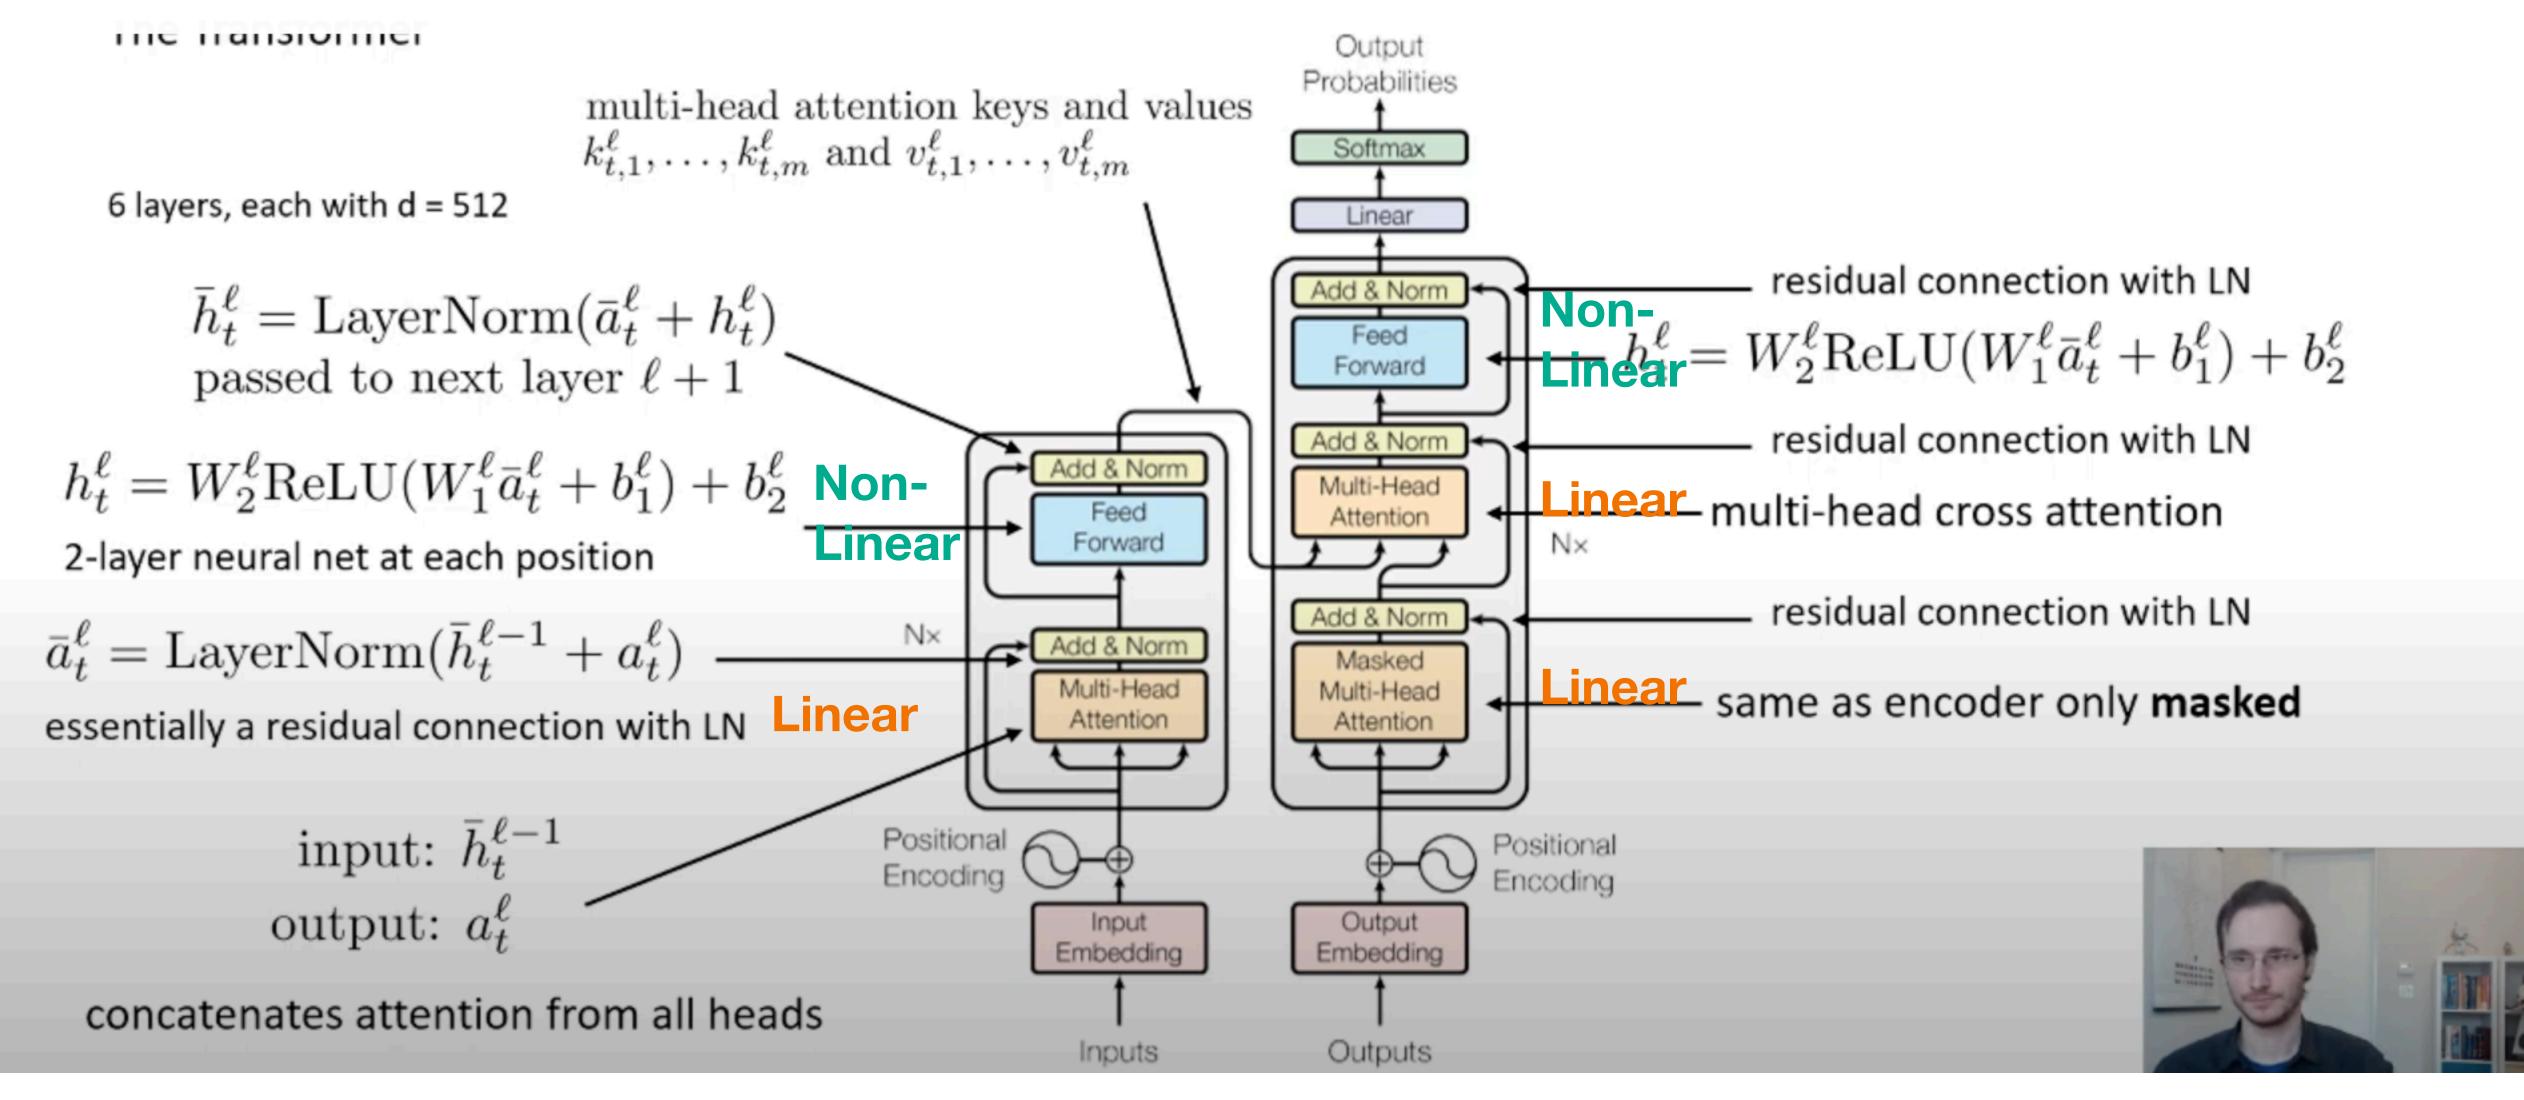
- Attention 은 rnn 처럼 이전 시점의 인풋 값들로만 output 을 추측하는 것이 아닌 오픈북 테스트
- 이를 방지하기 위해 실질적으로 결과물을 뱉어야하는 디코더에서는 masked multi-head attention 개념 도입



1-(3). <u>트랜스포머 전체 구조 & 코드</u>

부가적인 개념

Masked multi-head attention



"Why transformers >> rnn?"

Much better long-range connections Much easier to parallelize Can make it much deeper than RNN

코드: https://github.com/aladdinpersson/Machine-Learning-Collection/blob/master/ML/Pytorch/more advanced/transformer from scratch/transformer from scratch.py

출처: https://www.youtube.com/playlist? list=PL_iWQOsE6TfVmKkQHucjPAoRtIJYt8a5A&fbclid=IwAR3mDM dJgK-3bvyO2P95drPcvQd1VonMQ8cYJ06efPKKWW6Ui9-XwYIO3PA